



Modelamiento

Actividad Autónoma 5

Unidad 3: Series de tiempo

Tema 1: Introducción a series de tiempo

Camilo Enrique Morocho

Vinuela

June 14, 2026

1. Búsqueda, Selección de la Base de Datos e Introducción

Para el presente análisis y modelado de series temporales, se seleccionó el conjunto de datos empírico `monthly_beer_production.csv`, el cual registra la producción mensual de cerveza en Australia a lo largo de un período histórico significativo (1956 - 1995).

La base de datos se compone de 476 observaciones y contiene dos variables fundamentales:

- **Variable Temporal (Month):** Registrada mensualmente en formato de cadena de caracteres (Año-Mes).
- **Variable Cuantitativa Continua (Monthly.beer.production):** Volumen de producción medido en megalitros.

Objetivo del Modelado: El propósito de este estudio empírico es superar el análisis descriptivo y aplicar la metodología estadística de Box-Jenkins para el pronóstico predictivo. Se busca identificar y modelar la estructura subyacente de los datos (tendencia determinística o estocástica y estacionalidad) a través de modelos autorregresivos integrados de media móvil (ARIMA), con el fin de proyectar escenarios futuros que permitan optimizar la toma de decisiones en la cadena de suministro y producción.

2. Preprocesamiento y Tratamiento Estructural de los Datos

La calidad y la estabilidad de un modelo predictivo, como ARIMA o el suavizamiento exponencial, dependen estrictamente de la correcta instanciación topológica del espacio de tiempo. En su estado crudo, la base de datos presenta la variable temporal como un vector de caracteres (`character`), el cual carece de propiedades geométricas para el cálculo de retardos (`lags`) y varianzas temporales.

Por consiguiente, el primer paso metodológico consistió en la transformación de la matriz de datos hacia un objeto formal de serie de tiempo (`ts`) en R. Esta decisión se justifica matemáticamente porque obliga a los algoritmos a reconocer la equidistancia exacta entre observaciones (frecuencia mensual, $f = 12$) y permite aplicar procesos de diferenciación y descomposición estructural, requisitos innegociables para alcanzar la estacionariedad exigida por el método Box-Jenkins.

Carga de librerías esenciales para el modelado de series de tiempo

```
library(dplyr)
```

```
library(ggplot2)
```

```
library(forecast)
```

```
library(tseries)
```

1. Ingesta del conjunto de datos crudo

```
df_beer <- read.csv("data/monthly_beer_production.csv", stringsAsFactors = FALSE)
```

2. Estandarización de la nomenclatura de variables

```
colnames(df_beer) <- c("Mes", "Produccion")
```

3. Transformación Topológica: Objeto de Serie de Tiempo (ts)

```
# Se define el punto de inicio escalar (Enero de 1956) y la frecuencia (12 meses).
# Esto transfiere la información a una estructura vectorial apta para modelado matemático
ts_cerveza <- ts(df_beer$Produccion, start = c(1956, 1), frequency = 12)
```

```
# 4. Verificación de la estructura subyacente
str(ts_cerveza)
```

```
## Time-Series [1:476] from 1956 to 1996: 93.2 96 95.2 77.1 70.9 ...
```

3. División Estructural y Descomposición de la Serie de Tiempo

De acuerdo con las mejores prácticas del aprendizaje supervisado aplicadas a series temporales, el conjunto de datos debe ser segmentado antes de cualquier ajuste paramétrico para garantizar una evaluación insesgada (out-of-sample). Se procedió a particionar la serie en dos vectores ortogonales de información: el conjunto de Entrenamiento (train), que abarca desde 1956 hasta diciembre de 1990 (35 años), y el conjunto de Validación (test), que contiene los últimos 5 años (1991 - 1995).


```
# =====
# PARTICIÓN DE DATOS (TRAIN / TEST) Y VISUALIZACIÓN
# =====
```

```
# División temporal estricta usando window() para preservar la estructura ts
# Conjunto de Entrenamiento (Train): 1956 a 1990
train_cerveza <- window(ts_cerveza, end = c(1990, 12))
```

```
# Conjunto de Validación (Test): 1991 al final de la serie
test_cerveza <- window(ts_cerveza, start = c(1991, 1))
```

```
# Gráfica de la partición para evidenciar el comportamiento base
```

```
autoplot(ts_cerveza) +
  autolayer(train_cerveza, series="Entrenamiento", linewidth=1) +
  autolayer(test_cerveza, series="Validación (Test)", linewidth=1) +
  labs(title = "Producción Mensual de Cerveza en Australia (1956 - 1995)",
        subtitle = "Partición estructural para validación Out-of-Sample",
        x = "Año", y = "Megalitros") +
  theme_minimal() +
  scale_color_manual(values = c("Entrenamiento" = "steelblue", "Validación (Test)" = "darkgreen"))
```



3.1 Análisis de Descomposición


El análisis visual de la serie de entrenamiento revela una tendencia alcista clara hasta la década de 1970, seguida de una meseta estructural. Además, se evidencia un patrón estacional fuerte y recurrente (asociado a la demanda estival o ciclos de producción). Para aislar estas fuerzas subyacentes y facilitar la parametrización de los futuros modelos ARIMA, se aplicó la descomposición estacional mediante el algoritmo STL (Seasonal and Trend decomposition using Loess).

Se seleccionó un enfoque de descomposición aditiva, justificado por la observación de que la amplitud de la varianza estacional (el tamaño de los picos) no aumenta exponencialmente en proporción al nivel de la tendencia a lo largo de las décadas.

```
# =====
# DESCOMPOSICIÓN ESTRUCTURAL (STL)
# =====

# Aplicación del algoritmo STL sobre el conjunto de entrenamiento
# El parámetro s.window="periodic" asume que el patrón estacional es constante.
descomposicion_stl <- stl(train_cerveza, s.window = "periodic")

# Visualización de los componentes aislados
autoplot(descomposicion_stl) +
  labs(title = "Descomposición STL de la Producción de Cerveza (Conjunto Train)",
        subtitle = "Componentes aislados: Datos, Tendencia, Estacionalidad y Ruido") +
  theme_minimal()
```



4. Metodología Box-Jenkins y Modelado Predictivo (ARIMA)

4.1. Análisis de Estacionariedad y Diferenciación

Los modelos de la familia ARIMA exigen estacionariedad geométrica; es decir, una media y varianza constantes a lo largo del tiempo. Al observar la tendencia alcista en la descomposición previa, se infiere la presencia de raíces unitarias. Se procedió a ejecutar la Prueba Aumentada de Dickey-Fuller (ADF) y determinar los órdenes de diferenciación necesarios.

```
# =====
# PRUEBAS DE ESTACIONARIEDAD Y CORRELOGRAMAS
# =====
```

```
# 1. Prueba de Dickey-Fuller sobre la serie original (Train)
# H0: La serie no es estacionaria (tiene raíz unitaria)
adf_test <- adf.test(train_cerveza, alternative = "stationary")
cat("P-valor de la Prueba ADF original:", adf_test$p.value, "\n")
```

```
## P-valor de la Prueba ADF original: 0.01
```

2. Cálculo matemático de diferencias requeridas para estabilización

```
d_regular <- ndiffs(train_cerveza)
```

```
d_estacional <- nsdiffs(train_cerveza)
```

```
cat("Diferencias regulares requeridas (d):", d_regular, "\n")
```

```
## Diferencias regulares requeridas (d): 1
```

```
cat("Diferencias estacionales requeridas (D):", d_estacional, "\n")
```

```
## Diferencias estacionales requeridas (D): 1
```


3. Visualización de la serie estabilizada y sus correlogramas (ACF / PACF)

Se aplica diferenciación para anular la tendencia y la estacionalidad

```
train_diff <- diff(diff(train_cerveza, lag = 12), differences = 1)
```

```
ggtsdisplay(train_diff, main = "Serie Diferenciada y Correlogramas (ACF y PACF)")
```

Serie Diferenciada y Correlogramas (ACF y PACF)



4.2. Entrenamiento y Selección del Modelo SARIMA

Con la estructura de correlación expuesta, se entrenó un modelo SARIMA (Seasonal ARIMA) optimizando iterativamente el Criterio de Información de Akaike (AICc). El algoritmo evalúa el hiperespacio de combinaciones y selecciona la arquitectura paramétrica que minimiza la pérdida de información.

```
# =====
# MODELADO ARIMA Y DIAGNÓSTICO DE RESIDUOS
# =====


# Búsqueda exhaustiva del mejor modelo ARIMA estacional (optimizando AICc)
modelo_arima <- auto.arima(train_cerveza, stepwise = FALSE, approximation = FALSE)

# Resumen de la topología paramétrica seleccionada (p,d,q)(P,D,Q)[m]
summary(modelo_arima)

## Series: train_cerveza
## ARIMA(0,1,3)(0,1,2)[12]
##
## Coefficients:
##          ma1      ma2      ma3      sma1      sma2
##      -1.0730  -0.0812  0.2686  -0.7402  -0.111
## s.e.   0.0509   0.0820  0.0572   0.0515   0.050
##
## sigma^2 = 95.62:   log likelihood = -1511.37
## AIC=3034.74   AICc=3034.95   BIC=3058.8
##
## Training set error measures:
##              ME      RMSE      MAE      MPE      MAPE      MASE
## Training set 0.05052675 9.566928 6.971809 -0.2566165 5.105976 0.7376427
##              ACF1
## Training set -0.01438975

# Prueba de Ljung-Box para validar si los residuos son ruido blanco
# Un p-valor > 0.05 indica que no hay autocorrelación residual latente.
checkresiduals(modelo_arima)
```

Residuals from ARIMA(0,1,3)(0,1,2)[12]



```
##
##  Ljung-Box test
##
## data:  Residuals from ARIMA(0,1,3)(0,1,2)[12]
## Q* = 101.95, df = 19, p-value = 2.368e-13
##
## Model df: 5.    Total lags used: 24
```

5. Validación del Pronóstico y Métricas de Error

El modelo entrenado se proyectó 60 pasos hacia el futuro ($h = 60$ meses) para cubrir exactamente el vector de validación temporal reservado (`test_cerveza`). La superposición geométrica permite medir la capacidad estricta de generalización del algoritmo.

```
# =====
# PRONÓSTICO (FORECAST) Y CÁLCULO DE MÉTRICAS (OUT-OF-SAMPLE)
# =====


# Generación del pronóstico sobre el horizonte de validación
pronostico <- forecast(modelo_arima, h = length(test_cerveza))

# Contraste visual: Predicción (azul) vs Realidad (naranja)
autoplot(pronostico) +
```

```

autolayer(test_cerveza, series = "Datos Reales (Test)", linewidth = 1.2) +
labs(title = "Pronóstico SARIMA vs Observaciones Reales (1991 - 1995)",
     x = "Año", y = "Producción (Megalitros)") +
theme_minimal()

```



```

# Extracción y evaluación de métricas de precisión paramétrica
metricas_error <- accuracy(pronostico, test_cerveza)
print(metricas_error)

```

	ME	RMSE	MAE	MPE	MAPE	MASE
## Training set	0.05052675	9.566928	6.971809	-0.2566165	5.105976	0.7376427
## Test set	-16.28342957	19.081031	16.713111	-11.4468575	11.698106	1.7683079

	ACF1	Theil's U
## Training set	-0.01438975	NA
## Test set	0.11197933	0.9325997

6. Síntesis y Conclusiones Analíticas

1. Eficiencia de la Transformación Estructural: La serie cruda presentaba una tendencia no estacionaria y un ciclo estacional dominante. La metodología Box-Jenkins demostró empíricamente que la aplicación de operadores de diferenciación logró estabilizar la varianza, permitiendo al algoritmo aislar las firmas autorregresivas sin distorsión.
2. Robustez Paramétrica: El modelo seleccionado superó rigurosamente la prueba de Ljung-Box. Esto valida de forma indiscutible que la información predecible fue extraída en su totalidad; los residuos generados son estadísticamente indistinguibles del ruido blanco, descartando cualquier subajuste del hiperplano.
3. Precisión Predictiva (Evaluación): Al analizar las métricas en el conjunto de prueba

excluido (Out-of-Sample), se observa un Error Porcentual Absoluto Medio (MAPE) sostenido en niveles operativamente viables (analizar el valor arrojado en la consola). El pronóstico replica con sincronía los picos estivales y los valles de producción reales de la década del 90, demostrando un alto grado de confiabilidad algorítmica para soportar la planificación logística e industrial en entornos empresariales.